

FECAP - Fundação Escola de Comércio Álvares Penteado

Breno Sales Colaneri - 24026968
Guilherme Leão Rodrigues - 25027205
Izabelli Ribeiro dos Santos - 25027357
Rafael Chagas Silva - 25027262

**Projeto Interdisciplinar - Plataforma Analítica de Planejamento
Financeiro**

Entrega 1 de Análise Inferencial de Dados

São Paulo

Introdução

O objetivo desta primeira etapa do projeto foi realizar uma análise exploratória inicial na base de dados do Demonstrativo Fecap. O foco principal é entender o comportamento geral dos dados da coluna de valores contábeis, observando como eles estão distribuídos e identificando possíveis anomalias antes de avançarmos para as análises mais complexas.

Metodologia

O processamento dos dados foi executado em nuvem utilizando o ambiente do Google Colab. Todo o script foi escrito em Python, utilizando a biblioteca Pandas para a leitura do arquivo CSV, correção da formatação de milhares e separadores decimais, e para o cálculo exato das métricas estatísticas. Para a elaboração visual, os gráficos foram construídos utilizando as bibliotecas Matplotlib e Seaborn.

Tabela de Medidas Descritivas

Após o processamento da coluna de valores, foram extraídas as seguintes medidas de posição e dispersão da base:


Média	406.461.128,20
Mediana	-205.443,79
Moda	0,00
Variância	11.975.866.931.852.462.080,00
Desvio Padrão	3.460.616.553,72

Interpretação Numérica

Ao analisar essas métricas, o principal ponto de atenção é a diferença extrema entre a média e a mediana. Enquanto a média é puxada para um valor positivo na casa dos 406 milhões, a mediana, que corta os dados exatamente no meio, é negativa em aproximadamente 205 mil. Isso evidencia uma forte assimetria. A moda igual a zero reflete a natureza do arquivo: por se tratar de um demonstrativo com mais de um milhão de linhas, existe uma enorme concentração de contas sem movimento no período, saldos nulos ou campos vazios que o sistema exporta automaticamente como zero, fazendo com que este seja o número com maior frequência. Além disso, o desvio padrão na casa dos bilhões atesta que os dados possuem uma dispersão gigantesca em relação ao centro.

Visualização e Distribuição

Os gráficos confirmam visualmente o comportamento que as métricas matemáticas já indicavam. No histograma, observamos um pico muito alto concentrado no zero, acompanhado de caudas extremamente longas. No boxplot, a caixa que deveria mostrar a concentração principal dos dados aparece completamente esmagada. A linha densa que se estende até as extremidades, alcançando a marca dos 15 bilhões positivos e negativos, é a prova da presença massiva de valores atípicos, os outliers.



Conclusão Parcial

A partir desta análise descritiva, fica claro que os dados originais apresentam uma variabilidade muito alta, puxada por outliers que esticam a escala para a marca dos bilhões. No entanto, o principal insight desta etapa é que precisamos ter cautela no tratamento desses valores. Como estamos lidando com um demonstrativo financeiro, valores tão expressivos raramente são apenas ruídos nos dados ou erros de digitação; na prática, costumam representar movimentações reais, como contas de alto volume ou consolidações. Por isso, para as próximas etapas, a estratégia não será a exclusão cega desses extremos. Será obrigatório aplicar técnicas de limpeza e tratamento de forma muito mais direcionada, investigando o comportamento dessas contas atípicas. Se simplesmente apagarmos esses números para suavizar a curva estatística, a base continuará enviesada, mascarando a realidade do negócio e distorcendo qualquer análise futura ou construção de dashboards.

Anexo - Acesso ao Código Fonte

Todo o script em Python utilizado para o processamento, cálculo das métricas e geração das visualizações desta análise exploratória foi desenvolvido no Google Colab. O notebook completo está disponível para consulta e execução através do seguinte link:

[Colab Entrega 1 de Análise Inferencial de Dados](#)